SampleConnect RAG 参考アーキテクチャ

本資料では、SampleConnectの問い合わせ対応を支えるRAG基盤の構成要素と、主要なデータフローをまとめます。図で全体像を示したうえで、各コンポーネントの役割を補足します。

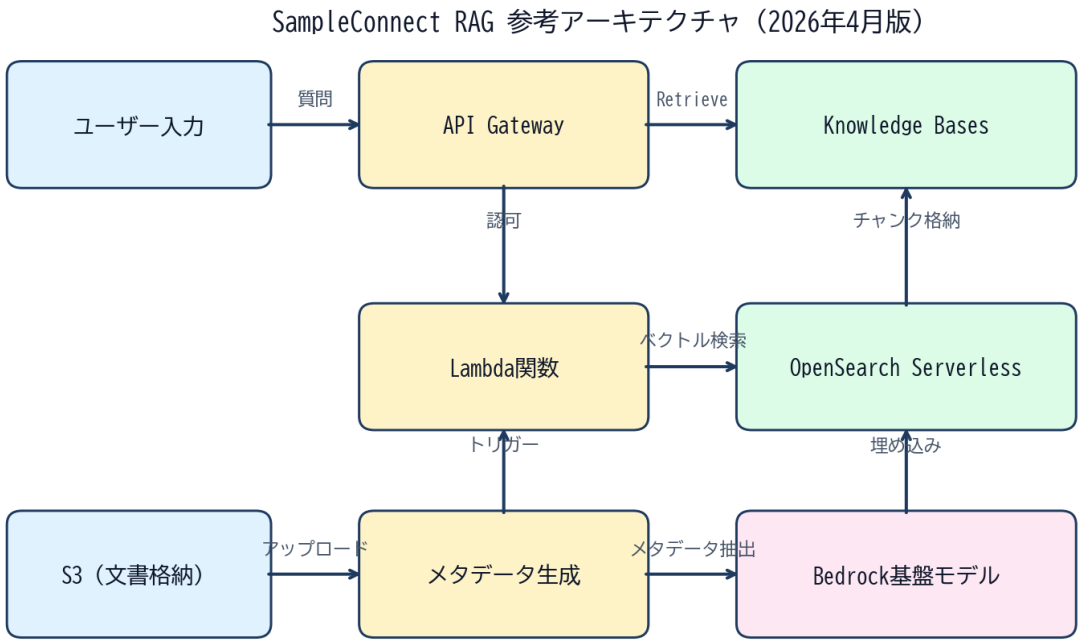


図1. SampleConnect RAG 参考アーキテクチャ。ユーザー入力はAPI Gatewayを経由してKnowledge Basesに渡り、OpenSearch Serverlessでベクトル検索、Bedrock基盤モデルで埋め込みと回答生成を行います。

コンポーネントの役割

コンポーネント	役割	補足
API Gateway	認証済みの質問を受け付ける入口	Cognito連携によりユーザー属性を付与
Lambda関数	リクエスト整形とKB呼び出し	audience属性に応じてフィルタを切り替え
Knowledge Bases	検索・回答生成の統合	RetrieveAndGenerate APIを使用
OpenSearch Serverless	ベクトルインデックスの格納	VECTORSEARCH コレクション
S3	原本ドキュメントの格納	.metadata.jsonサイドカーを同梱
メタデータ生成Lambda	サイドカーの自動生成	Structured Output方式を優先
Bedrock基盤モデル	埋め込み・応答生成・メタデータ抽出	Titan Embed v2 + Claude系